

# 1

## Regresión lineal simple

### 1.1 Introducción

Fue introducido por Francis Galton (1908). El modelo de regresión lineal simple está formado típicamente por:

$$y = \beta_0 + \beta_1 x + \epsilon.$$

Donde:

- $y$  = variable dependiente o variable de respuesta.
- $x$  = variable independiente o explicativo o predictor.
- $\beta_0$  = intercepto  $y$ .
- $\beta_1$  = pendiente.
- $\epsilon$  = error aleatorio.

Una presentación más general de un modelo de regresión sería:

$$y = E(y) + \epsilon,$$

Donde:  $E(y)$  es la esperanza matemática de la variable respuesta. Cuando  $E(y)$  es una combinación lineal de las variables explicativas  $x_1, x_2, \dots, x_k$  la regresión es una regresión lineal. Con  $E(\epsilon_i) = 0$  y  $Var(\epsilon_i) = \sigma^2$ . Todos los  $\epsilon_i$  son independientes.

Ahora debemos hallar buenos estimadores para  $\beta_0$  y  $\beta_1$ .

### 1.2 Estimaciones por mínimos cuadrados

El principal objetivo de los mínimos cuadrados para un modelo de regresión lineal simple es hallar los estimadores  $b_0$  y  $b_1$  tales que la suma de la distancia al cuadrados de la respuesta real  $y_i$  y las respuesta de las pronosticadas  $\hat{y}_i = \beta_0 + \beta_1 x_i$  alcanza el mínimo entre todas las opciones posibles de coeficientes de regresión  $\beta_0$  y  $\beta_1$ . Es decir,

$$(b_0, b_1) = \arg \min_{(\beta_0, \beta_1)} \sum_{i=1}^n [\beta_0 + \beta_1 x_i - y_i]^2.$$

Matemáticamente, las estimaciones de mínimos cuadrados de la regresión lineal simple se obtienen resolviendo el siguiente sistema:

$$\frac{\partial}{\partial \beta_0} \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2 = 0 \quad (1.1)$$

$$\frac{\partial}{\partial \beta_1} \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2 = 0 \quad (1.2)$$