

# 1

## Regresión lineal simple

### 1.1 Introducción

Fue introducido por Francis Galton (1908). El modelo de regresión lineal simple está formado típicamente por:

$$y = \beta_0 + \beta_1 x + \epsilon.$$

Donde:

- $y$  = variable dependiente o variable de respuesta.
- $x$  = variable independiente o explicativo o predictor.
- $\beta_0$  = intercepto  $y$ .
- $\beta_1$  = pendiente.
- $\epsilon$  = error aleatorio.

Una presentación más general de un modelo de regresión sería:

$$y = E(y) + \epsilon,$$

Donde:  $E(y)$  es la esperanza matemática de la variable respuesta. Cuando  $E(y)$  es una combinación lineal de las variables explicativas  $x_1, x_2, \dots, x_k$  la regresión es una regresión lineal. Con  $E(\epsilon_i) = 0$  y  $Var(\epsilon_i) = \sigma^2$ . Todos los  $\epsilon_i$  son independientes.

Ahora debemos hallar buenos estimadores para  $\beta_0$  y  $\beta_1$ .

### 1.2 Estimaciones por mínimos cuadrados

El principal objetivo de los mínimos cuadrados para un modelo de regresión lineal simple es hallar los estimadores  $b_0$  y  $b_1$  tales que la suma de la distancia al cuadrados de la respuesta real  $y_i$  y las respuesta de las pronosticadas  $\hat{y}_i = \beta_0 + \beta_1 x_i$  alcanza el mínimo entre todas las opciones posibles de coeficientes de regresión  $\beta_0$  y  $\beta_1$ . Es decir,

$$(b_0, b_1) = \arg \min_{(\beta_0, \beta_1)} \sum_{i=1}^n [\beta_0 + \beta_1 x_i]^2.$$

Matemáticamente, las estimaciones de mínimos cuadrados de la regresión lineal simple se obtienen resolviendo el siguiente sistema:

$$\frac{\partial}{\partial \beta_0} \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2 = 0 \quad (1.1)$$

$$\frac{\partial}{\partial \beta_1} \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2 = 0 \quad (1.2)$$

Supongamos que  $b_0$  y  $b_1$  son soluciones del sistema de arriba, podemos describir la relación entre  $x$  e  $y$  por la regresión lineal  $\hat{y} = b_0 + b_1 x$ , el cual es llamado la **recta de regresión ajustada**. Es más conveniente resolver para  $b_0$  y  $b_1$  usando el modelo lineal centralizado:

$$y_i = \beta_0 + \beta_1 \bar{x} - \beta_1 \bar{x} + \beta_1 x_i + \epsilon_i \Rightarrow y_i = \beta_0^* + \beta_1 (x_i - \bar{x}) + \epsilon_i,$$

donde  $\beta_0 = \beta_0^* - \beta_1 \bar{x}$ . Necesitamos resolver para

$$\frac{\partial}{\partial \beta_0^*} \sum_{i=1}^n [y_i - (\beta_0^* + \beta_1 (x_i - \bar{x}))]^2 = 0$$

$$\frac{\partial}{\partial \beta_1} \sum_{i=1}^n [y_i - (\beta_0^* + \beta_1 (x_i - \bar{x}))]^2 = 0$$

Realizando la derivada parcial para  $\beta_0$  y  $\beta_1$  tenemos

$$\sum_{i=1}^n [y_i - (\beta_0^* + \beta_1 (x_i - \bar{x}))] = 0$$

$$\sum_{i=1}^n [y_i - (\beta_0^* + \beta_1 (x_i - \bar{x}))] (x_i - \bar{x}) = 0$$

Notemos que

$$\sum_{i=1}^n y_i = n\beta_0^* + \sum_{i=1}^n \beta_1 (x_i - \bar{x}) = n\beta_0^* \quad (1.3)$$

Por lo tanto, tenemos

$$\beta_0^* = \frac{1}{n} \sum_{i=1}^n y_i = \bar{y}.$$

Luego, sustituyendo  $\beta_0^*$  por  $\bar{y}$  en (2.3) obtenemos

$$\sum_{i=1}^n [y_i - (\bar{y} + \beta_1 (x_i - \bar{x}))] (x_i - \bar{x}) = 0$$

Después denotamos  $b_0$  y  $b_1$  las soluciones de los sistemas (2.1) y (2.2). Ahora, es fácil ver que

$$b_1 = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}} \quad (1.4)$$

y

$$b_0 = b_0^* - b_1 \bar{x} = \bar{y} - b_1 \bar{x} \quad (1.5)$$

El valor ajustado de la regresión lineal simple es definida como  $\hat{y}_i = b_0 + b_1 x_i$ . La diferencia entre  $y_i$  y el valor ajustado  $\hat{y}_i$  es  $e_i = y_i - \hat{y}_i$ , que se refiere al residuo de la regresión. Los residuos de regresión se pueden calcular a partir de las respuestas observadas  $y_i$  y los valores ajustados  $\hat{y}_i$ , por lo tanto, los residuos son observables. Cabe señalar que el término de error  $\epsilon_i$  en el modelo de regresión no es observable. El error de regresión es la cantidad por la cual una observación difiere de su valor esperado; este último se basa en la población total de la que se eligió aleatoriamente la unidad estadística. El valor esperado, el promedio de toda la población, normalmente no es observable.

Un residual, por otro lado, es una estimación observable de un error no observable. El caso más simple implica una muestra aleatoria de  $n$  hombres cuyas alturas se miden. El promedio de la muestra se utiliza como una estimación del promedio de la población. Entonces, la diferencia entre la altura de cada hombre de la muestra y el promedio de la población no observable es un error, y la diferencia entre la altura de cada hombre de la muestra y el promedio de la muestra observable es un residuo. Dado que los residuales son observables, podemos usar los residuales para estimar el error del modelo no observable. La discusión detallada se proporcionará más adelante.

### 1.3 Propiedades estadísticas de la estimación por mínimos cuadrados

Primero discutiremos las propiedades estadísticas sin el supuesto de distribución del término de error. Pero asumiremos que  $E(\epsilon_i) = 0$ ,  $\text{Var}(\epsilon_i) = \sigma^2$  y  $\epsilon_i$  para  $i = 1, 2, \dots, n$  son independientes.

**Teorema 1.1** El estimador de mínimos cuadrados  $b_0$  es un estimador insesgado de  $\beta_0$ .

Demostración.-

$$\begin{aligned}
 E(b_0) &= E(\bar{y} - b_1 \bar{x}) \\
 &= E\left(\frac{1}{n} \sum_{i=1}^n y_i\right) - E(b_1 \bar{x}) \\
 &= \frac{1}{n} \sum_{i=1}^n E(y_i) - \bar{x} E(b_1) \\
 &= \frac{1}{n} \sum_{i=1}^n (\beta_0 + \beta_1 x_i) - \beta_1 \bar{x} \\
 &= \frac{1}{n} \sum_{i=1}^n \beta_0 + \beta_1 \frac{1}{n} \sum_{i=1}^n x_i - \beta_1 \bar{x} \\
 &= \frac{1}{n} \sum_{i=1}^n \beta_0 + \beta_1 \frac{1}{n} \sum_{i=1}^n x_i - \beta_1 \frac{1}{n} \sum_{i=1}^n x_i \\
 &= \frac{n\beta_0}{n} \\
 &= \beta_0.
 \end{aligned}$$



**Teorema** El estimador de mínimos cuadrados  $b_1$  es un estimador insesgado de  $\beta_1$ .

1.2

Demostración.-

$$\begin{aligned}
 E(b_1) &= E\left(\frac{S_{xy}}{S_{xx}}\right) \\
 &= \frac{1}{S_{xx}} E\left[\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})\right] \\
 &= \frac{1}{S_{xx}} \frac{1}{n} E\left[\sum_{i=1}^n (x_i - \bar{x})y_i - \sum_{i=1}^n (x_i - \bar{x})\bar{y}\right] \\
 &= \frac{1}{S_{xx}} \frac{1}{n} E\left[\sum_{i=1}^n (x_i - \bar{x})y_i - \bar{y} \sum_{i=1}^n (x_i - \bar{x})\right] \quad \text{ya que } \bar{y} \text{ es constante.}
 \end{aligned}$$

Sabemos que  $\sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n x_i - n\bar{x} = \sum_{i=1}^n x_i - n\left(\frac{1}{n} \sum_{i=1}^n x_i\right) = 0$ , por lo que

$$\begin{aligned}
 &= \frac{1}{S_{xx}} \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}) E(y_i) \\
 &= \frac{1}{S_{xx}} \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}) (\beta_0 + \beta_1 x_i) \\
 &= \frac{1}{S_{xx}} \frac{1}{n} \left[ \beta_0 \sum_{i=1}^n (x_i - \bar{x}) + \sum_{i=1}^n (x_i - \bar{x}) \beta_1 x_i \right] \\
 &= \frac{1}{S_{xx}} \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}) \beta_1 x_i \\
 &= \frac{1}{S_{xx}} \frac{1}{n} \left[ \sum_{i=1}^n (x_i - \bar{x}) \beta_1 x_i - \sum_{i=1}^n (x_i - \bar{x}) \beta_1 \bar{x} \right] \\
 &= \frac{1}{S_{xx}} \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}) \beta_1 (x_i - \bar{x}) \\
 &= \frac{1}{S_{xx}} \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \beta_1 \\
 &= \frac{S_{xx}}{S_{xx}} \beta_1 \\
 &= \beta_1.
 \end{aligned}$$

■

**Teorema 1.3**  $\text{Var}(b_1) = \frac{\sigma^2}{nS_{xx}}.$

Demostración.- Sea  $X_1, X_2, \dots, X_n$  IDD, con  $\text{Var}(X_i) = \sigma_i^2$  para  $i = 1, 2, \dots, n$ . Si  $\sum_{i=1}^n a_i X_i$ . Entonces,

$$\text{Var} \left( \sum_{i=1}^n a_i X_i \right) = \sum_{i=1}^n a_i^2 \sigma_i^2.$$

Por lo tanto,

$$\begin{aligned} \text{Var}(b_1) &= \text{Var} \left( \frac{S_{xy}}{S_{xx}} \right) \\ &= \left( \frac{1}{S_{xx}} \right)^2 \text{Var} \left[ \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x}) \right] \\ &= \frac{1}{S_{xx}^2} \text{Var} \left[ \frac{1}{n} \sum_{i=1}^n y_i (x_i - \bar{x}) \right] \\ &= \frac{1}{S_{xx}^2} \frac{1}{n^2} \sum_{i=1}^n (x_i - \bar{x})^2 \text{Var}(y_i) \\ &= \frac{1}{S_{xx}^2} \frac{1}{n^2} \sum_{i=1}^n (x_i - \bar{x})^2 \sigma^2 \\ &= \frac{\sigma^2}{nS_{xx}}. \end{aligned}$$

■

**Teorema 1.4** El estimador de mínimos cuadrados  $b_1$  e  $\bar{y}$  no están correlacionados. Bajo el supuesto de normalidad de  $y_i$  para  $i = 1, 2, \dots, n$ ,  $b_1$  e  $\bar{y}$  se distribuyen normalmente y son independientes.

Demostración.-

$$\begin{aligned} \text{Cov}(b_1, \bar{y}) &= \text{Cov} \left( \frac{S_{xy}}{S_{xx}}, \bar{y} \right) \\ &= \frac{1}{S_{xx}} \text{Cov}(S_{xy}, \bar{y}) \\ &= \frac{1}{nS_{xx}} \text{Cov} \left[ \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}), \bar{y} \right] \\ &= \frac{1}{n^2 S_{xx}} \text{Cov} \left[ \sum_{i=1}^n (x_i - \bar{x}) y_i, \sum_{i=1}^n y_i \right] \\ &= \frac{1}{n^2 S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) \text{Cov}(y_i, y_j) \end{aligned}$$

Notemos que  $E(\epsilon_i) = 0$  y  $\epsilon_i$  son independientes. De donde por definición de covarianza, podemos

escribir

$$\text{Cov}(y_i, y_j) = E \{ [y_i - E(y_i)][y_j - E(y_j)] \} = E(\epsilon_i, \epsilon_j) = \begin{cases} \sigma^2 & \text{si } i = j \\ 0 & \text{si } i \neq j. \end{cases}$$

Concluimos que

$$\text{Cov}(b_1, \bar{y}) = \frac{1}{n^2} S_{xx} \sum_{i=1}^n (x_i - \bar{x}) \sigma^2 = 0.$$

Recuerde que la correlación cero es equivalente a la independencia entre dos variables normales. Por lo tanto, concluimos que  $b_1$  e  $\bar{y}$  son independientes. ■

**Teorema 1.5**  $\text{Var}(b_0) = \left( \frac{1}{n} + \frac{\bar{x}^2}{nS_{xx}} \right) \sigma^2.$

Demostración.- Sea,  $X_1, X_2, \dots, X_n$  IDD, y  $E(X) = \mu$  y  $\text{Var}(X) = \sigma^2$ . Entonces, la media muestral  $\bar{X}$  es normal con media  $\mu$  y varianza  $\frac{\sigma^2}{n}$ . Por lo tanto,

$$\begin{aligned} \text{Var}(b_0) &= \text{Var}(\bar{y} - b_1 \bar{x}) \\ &= \text{Var}(\bar{y}) + (\bar{x})^2 \text{Var}(b_1) \\ &= \frac{\sigma^2}{n} + \bar{x}^2 \frac{\sigma^2}{nS_{xx}} \\ &= \left( \frac{1}{n} + \frac{\bar{x}^2}{nS_{xx}} \right) \sigma^2 \end{aligned}$$

■

Las varianzas de  $b_0$  y  $b_1$  son importantes cuando queremos hacer inferencias estadísticas sobre la intersección y la pendiente de la regresión.

Dado que las varianzas de los estimadores de mínimos cuadrados  $b_0$  y  $b_1$  involucran la varianza del término de error en el modelo de regresión simple. Esta variación de error es desconocida para nosotros. Por lo tanto, necesitamos estimarlo. Ahora discutimos cómo estimar la varianza del término de error en el modelo de regresión lineal simple. Sea  $y_i$  la variable de respuesta observada y  $\hat{y}_i = b_0 + b_1 x_i$ , el valor ajustado de la respuesta. Tanto  $y_i$  como  $\hat{y}_i$  están disponibles para nosotros. El verdadero error  $\sigma_i$  en el modelo no es observable y nos gustaría estimarlo. La cantidad  $y_i - \hat{y}_i$  es la versión empírica del error  $\epsilon_i$ . Esta diferencia es un residuo de regresión que juega un papel importante en el diagnóstico del modelo de regresión. Proponemos la siguiente estimación de la varianza del error basada en  $e_i$ :

$$s^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Tenga en cuenta que en el denominador es  $n-2$ . Esto hace que  $s^2$  sea un estimador insesgado de la varianza del error  $\sigma^2$ . El modelo lineal tiene dos parámetros, por lo que,  $n-2$  puede verse como  $n$  - números de parámetros simples. En particular, en un modelo de regresión lineal múltiple con  $p$  parámetros, el denominador debe ser  $n-p$  para construir un estimador insesgado de la varianza del error  $\sigma^2$ .

El estimador insesgado  $s^2$  para la regresión lineal simple será demostrado en las siguientes derivaciones.

$$y_i - \hat{y}_i = y_i - b_0 - b_1 x_i = y_i - (\bar{y} - b_1 \bar{x}) - b_1 x_i$$

Estamos suponiendo que  $E(\epsilon) = 0$ ; de lo que se sigue,

$$\sum_{i=1}^n (y_i - \hat{y}_i) = \sum_{i=1}^n (y_i - \bar{y}) = \sum_{i=1}^n (y_i - \bar{y}) - b_i \sum_{i=1}^n (x_i - \bar{x}) = 0.$$

Demostremos este supuesto. Note que  $(y_i - \hat{y}_i) x_i = [(y_i - \bar{y}) - b_i (x_i - \bar{x})] x_i$ , de donde

$$\begin{aligned} \sum_{i=1}^n (y_i - \hat{y}_i) x_i &= \sum_{i=1}^n [(y_i - \bar{y}) x_i - b_i (x_i - \bar{x})] x_i \\ \sum_{i=1}^n (y_i - \hat{y}_i) &= \sum_{i=1}^n [(y_i - \bar{y}) x_i - b_i (x_i - \bar{x})] (x_i - \bar{x}) \\ &= \sum_{i=1}^n (y_i - \bar{y}) (x_i - \bar{x}) - b_i \sum_{i=1}^n (x_i - \bar{x})^2 \\ &= n (S_{xy} - b_1 S_{xx}) \\ &= n \left( S_{xy} - \frac{S_{xy}}{S_{xx}} S_{xx} \right) \\ &= 0. \end{aligned}$$

Para demostrar que  $s^2$  es un estimador insesgado de la varianza del error, primero veamos que

$$(y_i - \hat{y}_i)^2 = [(y_i - \bar{y}) - b_i (x_i - \bar{x})]^2,$$

Por lo que

$$\begin{aligned} \sum_{i=1}^n (y_i - \hat{y}_i)^2 &= \sum_{i=1}^n [(y_i - \bar{y}) - b_i (x_i - \bar{x})]^2 \\ &= \sum_{i=1}^n (y_i - \bar{y})^2 - 2b_i \sum_{i=1}^n (x_i - \bar{x}) (y_i - \bar{y}) + b_i^2 \sum_{i=1}^n (x_i - \bar{x})^2 \\ &= \sum_{i=1}^n (y_i - \bar{y})^2 - 2nb_i S_{xy} + nb_i^2 S_{xx} \\ &= \sum_{i=1}^n (y_i - \bar{y})^2 - 2n \frac{S_{xy}}{S_{xx}} S_{xy} + n \frac{S_{xy}^2}{S_{xx}^2} S_{xx} \\ &= \sum_{i=1}^n (y_i - \bar{y})^2 - n \frac{S_{xy}^2}{S_{xx}} \end{aligned}$$

Después, ya que

$$\begin{aligned} (y_i - \bar{y})^2 &= [\beta_0 + \beta_1 x_i + \epsilon_i - (\beta_0 + \beta_1 \bar{x} + \bar{\epsilon})]^2 \\ &= [\beta_1 (x_i - \bar{x}) + (\epsilon_i - \bar{\epsilon})]^2 \\ &= \beta_1^2 (x_i - \bar{x})^2 + (\epsilon_i - \bar{\epsilon})^2 + 2\beta_1 (x_i - \bar{x}) (\epsilon_i - \bar{\epsilon}) \end{aligned}$$

Entonces, en vista que  $E(\epsilon_i - \bar{\epsilon}) = 0$  tenemos

$$\begin{aligned}
E(y_i - \bar{y})^2 &= \beta_1^2 (x_i - \bar{x})^2 + E(\epsilon_i - \bar{\epsilon})^2 \\
&= \beta_1^2 (x_i - \bar{x})^2 + E(\epsilon_i - \bar{\epsilon})^2 - E^2(\epsilon_i - \bar{\epsilon}) + E^2(\epsilon_i - \bar{\epsilon}) \\
&= \beta_1^2 (x_i - \bar{x})^2 + \text{Var}(\epsilon_i - \bar{\epsilon}) \\
&= \beta_1^2 (x_i - \bar{x})^2 + \text{Var}(\epsilon_i) + \text{Var}(\bar{\epsilon}) - 2\text{Cov}(\epsilon_i, \bar{\epsilon}) \\
&= \beta_1^2 (x_i - \bar{x})^2 + \sigma^2 + \frac{\sigma^2}{n} - 2\frac{\sigma^2}{n} \\
&= \beta_1^2 (x_i - \bar{x})^2 + \frac{n-1}{n}\sigma^2,
\end{aligned}$$

y

$$\begin{aligned}
\sum_{i=1}^n E(y_i - \bar{y})^2 &= n\beta_1^2 S_{xx} + \sum_{i=1}^n \frac{n-1}{n}\sigma^2 \\
&= n\beta_1^2 S_{xx} + (n-1)\sigma^2.
\end{aligned}$$

Además, se tiene

$$\begin{aligned}
E(S_{xy}) &= E\left[\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})\right] \\
&= \frac{1}{n} E\left[\sum_{i=1}^n (x_i - \bar{x}) y_i\right] \\
&= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}) E(y_i) \\
&= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}) (\beta_0 + \beta_1 x_i) \\
&= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}) \beta_0 + \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}) \beta_1 x_i \\
&= \frac{1}{n} \beta_0 \sum_{i=1}^n x_i - \frac{1}{n} \beta_0 \sum_{i=1}^n x_i + \frac{1}{n} \beta_1 \sum_{i=1}^n (x_i - \bar{x}) x_i \\
&= \frac{1}{n} \beta_0 \left[ \sum_{i=1}^n (x_i - \bar{x}) x_i - \sum_{i=1}^n (x_i - \bar{x}) \bar{x} \right] \\
&= \frac{1}{n} \beta_0 \sum_{i=1}^n (x_i - \bar{x})^2 \\
&= \frac{1}{n} \beta_0 S_{xx}
\end{aligned}$$



También; sea  $X_1, X_2, \dots, X_n$  IDD, con  $\text{Var}(X_i) = \sigma_i^2$  para  $i = 1, 2, \dots, n$ . Si  $\sum_{i=1}^n a_i X_i$ . Entonces,

$$\text{Var} \left( \sum_{i=1}^n a_i X_i \right) = \sum_{i=1}^n a_i^2 \sigma_i^2.$$

Por lo tanto,

$$\begin{aligned} \text{Var}(S_{xy}) &= \text{Var} \left[ \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}) y_i \right] \\ &= \frac{1}{n^2} \sum_{i=1}^n (x_i - \bar{x})^2 \text{Var}(y_i) \\ &= \frac{1}{n} S_{xx} \sigma^2. \end{aligned}$$

Así, podemos escribir

$$\begin{aligned} \text{Var}(S_{xy}^2) &= E(S_{xy}^2) - E^2(S_{xy}) \\ E(S_{xy}^2) &= \text{Var}(S_{xy}) + E^2(S_{xy}) \\ &= \frac{1}{n} S_{xx} \sigma^2 + \beta_1^2 S_{xx}^2. \end{aligned}$$

y

$$E(S_{xy}^2) = \frac{1}{n} S_{xx} (\sigma^2 + n \beta_1^2 S_{xx})$$

Dado que  $E(S_{xx}) = S_{xx}$ , entonces

$$E \left( \frac{n S_{xy}^2}{S_{xx}} \right) = \sigma^2 + n \beta_1^2 S_{xx}.$$

Finalmente,  $E(\hat{\sigma}^2)$  es dado por:

$$\begin{aligned} E \left[ \sum_{i=1}^n (y_i - \hat{y}_i)^2 \right] &= E \left[ \sum_{i=1}^n (y_i - \bar{y})^2 \right] - E \left[ n \frac{S_{xy}^2}{S_{xx}} \right] \\ &= n \beta_1^2 S_{xx} + (n-1) \sigma^2 - n \beta_1^2 S_{xx} - \sigma^2 \\ &= (n-2) \sigma^2. \end{aligned}$$

En otras palabras, probamos que

$$E(s^2) = E \left[ \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \right] = \sigma^2.$$

Por lo tanto,  $s^2$ , la estimación de la varianza del error, es un estimador insesgado de la varianza del error  $\sigma^2$  en la regresión lineal simple. Otra vista de elegir  $n-2$  es que en el modelo de regresión lineal simple hay  $n$  observaciones y dos restricciones sobre estas observaciones:

$$\text{i) } \sum_{i=1}^n (y_i - \hat{y}) = 0,$$

$$\text{ii) } \sum_{i=1}^n (y_i - \hat{y}) x_i = 0.$$

Por lo tanto, la estimación de la varianza del error tiene  $n - 2$  grados de libertad, que también es el número total de observaciones - el número total de parámetros en el modelo. Veremos características similares en la regresión lineal múltiple.

#### 1.4 Estimación de máxima verosimilitud

El estimador de máxima verosimilitud de una regresión lineal simple puede ser desarrollado si se supone que la variable dependiente  $y_i$  tiene una distribución normal  $y_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$ . La función de similitud para  $(y_1, y_2, \dots, y_n)$  es dada por:

$$L = \prod_{i=1}^n f(y_i) = \frac{1}{(2\pi)^{\frac{n}{2}} \sigma^n} e^{\left(-\frac{1}{2\sigma^2}\right) \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2}$$

Los estimadores de  $\beta_0$  y  $\beta_1$  que maximiza la función de similitud  $L$  son equivalentes a los estimadores que minimizan la parte exponencial de la función de verosimilitud lo que produce los mismos estimadores que los estimadores de mínimos cuadrados de la regresión lineal. Por lo tanto, bajo el supuesto de normalidad del término de error, los MLE de  $\beta_0$  y  $\beta_1$  y los estimadores de mínimos cuadrados de  $\beta_0$  y  $\beta_1$  son exactamente iguales.

Después de obtener  $b_0$  y  $b_1$ , los valores MLE de los parámetros  $\beta_0$  y  $\beta_1$ , podemos calcular el valor ajustado  $\hat{y}_i$  y la función de probabilidad en términos de los valores ajustados.

$$L = \prod_{i=1}^n f(y_i) = \frac{1}{(2\pi)^{\frac{n}{2}} \sigma^n} e^{\left(-\frac{1}{2\sigma^2}\right) \sum_{i=1}^n (y_i - \hat{y}_i)^2}.$$

Luego, tomamos la derivada parcial con respecto a  $\sigma^2$  en la función logarítmica de verosimilitud  $\log(L)$  y la igualamos a cero:

$$\frac{\partial \log(L)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = 0$$

La estimación de máxima verosimilitud MLE de  $\sigma^2$  es  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$ . Notemos que es un estimador sesgado de  $\sigma^2$ , ya que  $s^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2$  es un estimador insesgado del error de la varianza

$\sigma^2$ .  $\frac{n}{n-2} \hat{\sigma}^2$  es un estimador insesgado de  $\sigma^2$ . Observe también que  $\hat{\sigma}^2$  es una estimación asintóticamente insesgada de  $\sigma^2$ , lo que coincide con la teoría clásica de MLE.

### 1.5 Intervalo de confianza sobre la media de regresión y la predicción de regresión

Los modelos de regresión suelen construirse basándose en determinadas condiciones que deben verificarse para que el modelo se ajuste bien a los datos y pueda predecir la respuesta para un determinado regresor con la mayor precisión posible. Uno de los principales objetivos del análisis de regresión es utilizar el modelo de regresión ajustado para realizar predicciones.

El intervalo de confianza de la predicción de regresión permite evaluar la calidad de la predicción. A menudo interesan los siguientes intervalos de confianza de la predicción de regresión:

- Un intervalo de confianza para una sola línea de regresión.
- Un intervalo de confianza para un solo valor futuro de  $y$  correspondiente a un valor elegido de  $x$ .
- Una región de confianza para la línea de regresión como un todo.

Para analizar el intervalo de confianza para la línea de regresión, consideramos el valor ajustado de la línea de regresión en  $x = x_0$ , que es  $\hat{y}(x_0) = b_0 + b_1 x_0$  y el valor medio de  $x = x_0$  es  $E(\hat{y}|x_0) = \beta_0 + \beta_1 x_0$ . Tenga en cuenta que  $b_1$  es independiente de  $\bar{y}$  de donde,

$$\begin{aligned} \text{Var}[\hat{y}(x_0)] &= \text{Var}(b_0 + b_1 x_0) \\ &= \text{Var}[\bar{y} - b_1(x_0 - \bar{x})] \\ &= \text{Var}(\bar{y}) + (x_0 - \bar{x})^2 \text{Var}(b_1) \\ &= \frac{1}{n} \sigma^2 + (x_0 - \bar{x})^2 \frac{1}{S_{xx}} \sigma^2 \\ &= \sigma^2 \left[ \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right] \end{aligned}$$

Reemplazando  $\sigma$  por  $s$ , el error estandar de la predicción de regresión en  $x_0$  está dado por:

$$s_{\hat{y}}(x_0) = s \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}$$

Si  $\epsilon \sim N(0, \sigma^2)$  el  $(1 - \alpha)100\%$  del intervalo de confianza en  $E(\hat{y}|x_0) = \beta_0 + \beta_1 x_0$  puede escribirse como:

$$\hat{y}(x_0) \pm t_{\alpha/2, n-2} s \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}.$$

Ahora, analicemos el intervalo de confianza en la predicción de la regresión. Denotemos la predicción de la regresión en  $x_0$  por  $y_0$  y supongamos que  $y_0$  es independiente de  $\hat{y}(x_0)$ , donde  $y(x_0) = b_0 + b_1 x_0$ , y  $E[y - \hat{y}(x_0)] = 0$ . Ya que  $\text{Var}(X - Y) = \text{Var}(X) + \text{Var}(Y) - 2\text{Cov}(X, Y)$  con  $\text{Cov}(X, Y) = 0$ . Entonces,

$$\begin{aligned} \text{Var}[y_0 - \hat{y}(x_0)] &= \sigma^2 + \sigma^2 \left[ \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right] \\ &= \sigma^2 \left[ 1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right] \end{aligned}$$

Bajo el supuesto de normalidad del término de error

$$\frac{y_0 - \hat{y}(x_0)}{\sigma \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}} \sim N(0, 1).$$

Luego, sustituyendo  $\sigma$  con  $s$  se tiene

$$\frac{y_0 - \hat{y}(x_0)}{s \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}} \sim t_{n-2}.$$

Así, el  $(1 - \alpha)100\%$  del intervalo de confianza en la predicción de la regresión en  $y_0$  puede ser expresada como

$$\hat{y}_0 \pm t_{\alpha/2, n-2} s \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}$$

### 1.6 Inferencia estadística sobre parámetros de regresión

Para dividir la varianza total  $\sum_{i=1}^n (y_i - \bar{y})^2$ , consideremos la ecuación de regresión ajustada  $\hat{y}_i = b_0 + b_1 x_i$ , donde  $b_0 = \bar{y} - b_1 \bar{x}$  y  $b_1 = \frac{S_{xy}}{S_{xx}}$ . Podemos escribir

$$\begin{aligned} \bar{\hat{y}} &= \frac{1}{n} \sum_{i=1}^n \hat{y}_i \\ &= \frac{1}{n} \sum_{i=1}^n [(\bar{y} - b_1 \bar{x}) + b_1 x_i] \\ &= \frac{1}{n} \sum_{i=1}^n [\bar{y} + b_1 (x_i - \bar{x})] \quad \text{ya que } \frac{1}{n} \sum x_i - \frac{1}{n} \sum \bar{x} = 0 \\ &= \bar{y}. \end{aligned}$$

Para la respuesta de la regresión  $y_i$ , la varianza total es  $\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$ . Note que la varianza total puede ser dividida en dos partes:

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 &= \frac{1}{n} \sum_{i=1}^n [(y_i - \hat{y}_i) + (\hat{y}_i - \bar{y})]^2 \\ &= \frac{1}{n} \sum_{i=1}^n \left[ (y_i - \hat{y}_i)^2 + (\hat{y}_i - \bar{y})^2 + 2 (\hat{y}_i - \bar{y}) (y_i - \hat{y}_i) \right] \\ &= \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \\ &= SS_{Reg} + SS_{Res} \\ &= \text{Varianza explicada por la regresión} + \text{Varianza no explicada} \end{aligned}$$

Se puede demostrar que  $[2 (y_i - \hat{y}_i) (\hat{y}_i - \bar{y})]$  es cero. Usando el hecho de que  $\sum_{i=1}^n (y_i - \hat{y}_i) = 0$ , tenemos

$$\begin{aligned}
\sum_{i=1}^n (\hat{y}_i - \bar{y}) (y_i - \hat{y}_i) &= \sum_{i=1}^n \hat{y}_i (y_i - \hat{y}_i) \\
&= \sum_{i=1}^n [(b_0 + b_1 x_i) (y_i - \hat{y}_i)] \\
&= b_0 \sum_{i=1}^n (y_i - \hat{y}_i) + b_1 \sum_{i=1}^n x_i (y_i - \hat{y}_i) \\
&= b_1 \sum_{i=1}^n x_i (y_i - \hat{y}_i) \\
&= b_1 \sum_{i=1}^n x_i (y_i - b_0 - b_1 x_i) \\
&= b_1 \sum_{i=1}^n x_i [(y_i - \bar{y}) - b_1 (x_i - \bar{x})] \\
&= b_1 \left[ \sum_{i=1}^n x_i (y_i - \bar{y}) - \bar{x} (y_i - \bar{y}) - b_1 x_i (x_i - \bar{x}) - b_1 \bar{x} (x_i - \bar{x}) \right] \\
&= b_1 \left[ \sum_{i=1}^n [(x_i - \bar{x}) (y_i - \bar{y})] - b_1 \sum_{i=1}^n (x_i - \bar{x})^2 \right] \\
&= b_1 (S_{xy} - b_1 S_{xx}) \\
&= b_1 \left[ S_{xy} - \left( \frac{S_{xy}}{S_{xx}} \right) S_{xx} \right] \\
&= 0.
\end{aligned}$$

Los grados de libertad para  $SS_{Reg}$  y  $SS_{Res}$  se muestran a continuación:

---


$$\begin{aligned}
SS_{Total} &= SS_{Reg} + SS_{Res} \\
n - 1 &= 1 + n - 2
\end{aligned}$$


---

Para probar la hipótesis  $H_0 : \beta_1 = 0$  contra  $H_1 : \beta_1 \neq 0$  es necesario asumir que  $\epsilon_i \sim N(0, \sigma^2)$ . La siguiente tabla contiene las distribuciones de  $SS_{Reg}$ ,  $SS_{Res}$  y  $SS_{Total}$  bajo la hipótesis  $H_0$ .

---

SS	df	distribucin
$SS_{Reg}$	1	$\sigma^2 \chi_1^2$
$SS_{Res}$	$n - 2$	$\sigma^2 \chi_{n-2}^2$
$SS_{Total}$	$n - 1$	$\sigma^2 \chi_{n-1}^2$

---

El test estadístico está dado por:

$$F = \frac{\frac{SS_{Reg}}{SS_{Res}}}{\frac{n-1}{n-2}} \sim F_{1,n-2},$$

que es una prueba  $F$  unilateral superior. La tabla de abajo muestra un típico análisis de varianza (anova) de regresión

<i>Fuente</i>	<i>SS</i>	<i>df</i>	<i>MS</i>	<i>F</i>
<i>Regresion</i>	$SS_{Reg}$	1	$\frac{SS_{Reg}}{1}$	$\frac{MS_{Reg}}{s^2}$
<i>Residuo</i>	$SS_{Res}$	$n-2$	$s^2$	
<i>Total</i>	$SS_{Total}$	$n-1$		

Para comprobar la pendiente de regresión  $\beta_1$ . Se observa que  $b_1$  sigue la distribución normal

$$b_1 \sim N\left(\beta_1, \frac{\sigma^2}{SS_{xx}}\right)$$

y

$$\left(\frac{b_1 - \beta_1}{s}\right) \sqrt{SS_{xx}} \sim t_{n-2}$$

que puede utilizarse para comprobar  $H_0 : \beta_1 = \beta_{10}$  contra  $H_1 : \beta_1 \neq \beta_{10}$ . Se puede utilizar un enfoque similar para comprobar el intercepto de la regresión. Bajo el supuesto de normalidad normalidad del término de error

$$b_0 \sim N\left[\beta_0, \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{SS_{xx}}\right)\right].$$

Así, podemos usar el estadístico t test con  $H_0 : \beta_0 = \beta_{00}$  contra  $H_1 : \beta_0 \neq \beta_{00}$ .

$$t = \frac{b_0 - \beta_0}{s \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{SS_{xx}}}} \sim t_{n-2}$$

Es sencillo usar las distribuciones de  $b_0$  y  $b_1$  para obtener los  $(1 - \alpha)100\%$  intervalos de confianza de  $\beta_0$  y  $\beta_1$ :

$$b_0 \pm t_{\alpha/2, n-2} s \sqrt{\frac{1}{n} + \frac{\bar{n}^2}{SS_{xx}}},$$

y

$$b_1 \pm t_{\alpha/2, n-2} s \sqrt{\frac{1}{SS_{xx}}}.$$

Supongamos que la linea de regresión pasa a través de  $(0, \beta_0)$ . Es decir, el intercepto en  $y$  es una constante conocida  $\beta_0$ . El modelo es dado por  $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$  con una constante conocida  $\beta_0$ . Usando el principio de mínimos cuadrados podemos estimar  $\beta_1$ :

$$b_1 = \frac{\sum x_i y_i}{\sum x_i^2}$$

En consecuencia, el siguiente estadístico t test se puede utilizar para probar  $H_0 : \beta_1 = \beta_{10}$  contra  $H_1 : \beta_1 \neq \beta_{10}$ . Bajo el supuesto de normalidad sobre  $\epsilon_i$

$$t = \frac{b_1 - \beta_{10}}{s} \sqrt{\sum_{i=1}^n x_i^2} \sim t_{n-1}$$

Tenga en cuenta que solo tenemos un parámetro para el modelo de regresión del intercepto  $y$  donde la estadística de t test tiene  $n - 1$  grados de libertad, que es diferente del modelo lineal simple con 2 parámetros.

La cantidad  $R^2$ , definida a continuación, es una medida de ajuste de regresión:

$$R^2 = \frac{SS_{Reg}}{SS_{Total}} = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{SS_{Res}}{SS_{Total}}$$

Notemos que  $0 \leq R^2 \leq 1$  que representa la proporción de variación total explicada para el modelo de regresión.

la cantidad  $CV = \frac{s}{\bar{y}} \times 100$  se llama coeficiente de variación, que también es una medida de la calidad del ajuste y representa la dispersión del ruido alrededor de la línea de regresión.

Ahora discutimos la inferencia simultánea en la regresión lineal simple. Tenga en cuenta que hasta ahora hemos discutido la inferencia estadística sobre  $\beta_0$  y  $\beta_1$  individualmente. La prueba individual significa que cuando probamos  $H_0 : \beta_0 = \beta_{00}$  solo probamos esta  $H_0$  independientemente de los valores de  $\beta_1$ . Asimismo, cuando probamos  $H_0 : \beta_1 = \beta_{10}$  solo probamos  $H_0$  independientemente de los valores de  $\beta_0$ . Si quisiéramos probar si una línea de regresión cae o no en cierta región, necesitamos probar la hipótesis múltiple:  $H_0 : \beta_0 = \beta_{00}, \beta_1 = \beta_{10}$  simultáneamente. Esto cae en el ámbito de la inferencia múltiple. Para la inferencia múltiple sobre  $\beta_0$  y  $\beta_1$  notamos que

$$(b_0 - \beta_0, b_1 - \beta_1) \begin{pmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{pmatrix} \begin{pmatrix} b_0 - \beta_0 \\ b_1 - \beta_1 \end{pmatrix} \sim 2s^2 F_{2, n-2}$$

Así, la región de confianza  $(1 - \alpha)100\%$  de  $\beta_0$  y  $\beta_1$  es dado por

$$(b_0 - \beta_0, b_1 - \beta_1) \begin{pmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{pmatrix} \begin{pmatrix} b_0 - \beta_0 \\ b_1 - \beta_1 \end{pmatrix} \leq 2s^2 F_{2, n-2},$$

donde  $F_{\alpha, 2, n-2}$  es a cola superior del  $\alpha$ -ésimo punto porcentual de la distribución  $F$ . Tenga en cuenta que esta región de confianza es una elipse.

## 1.7 Análisis residual y diagnóstico del modelo