

# Variables aleatorias discretas

Christian Limbert Paredes Aguilera

1/12/2021

## Definición de variable aleatoria

Una variable aleatoria es una aplicación que toma valores numéricos determinados por el resultado de un experimento aleatorio.

## Tipos de variables aleatorias

Variables aleatorias discretas, continua y mixtas.

## Función de probabilidad para variables discretas

La función de probabilidad de una variable aleatoria discreta  $X$  es la que denotamos por

$$P_X(x) = P(X = x)$$

Dominio de una variable aleatoria discreta

$$D_X = \{x \in \mathbb{R} \mid P_X(x) > 0\}$$

en el caso discreto lo mas habitual es que

$$X(\Omega) = D_X$$

## Propiedades de la función de probabilidad

Sea  $X$  una v.a. discreta  $X : \Omega \Rightarrow \mathbb{R}$  con dominio  $D_X$ . Su función de probabilidad  $P_X$  verifica las siguientes propiedades:

- $0 \leq P_X(x) \leq 1$  para todo  $x \in \mathbb{R}$
- $\sum_{x \in D_X} P_X(x) = 1$

$$P_X(x) = \begin{cases} \frac{1}{8} & \text{si } x = 0, 3 \\ \frac{3}{8} & \text{si } x = 1, 2 \\ 0 & \text{en otro caso} \end{cases}$$

Efectivamente los valores de la función de distribución suman 1

$$\sum_{x=0}^3 P_X(x) = \frac{1}{8} + \frac{3}{8} + \frac{3}{8} + \frac{1}{8} = 1$$

## Función de distribución de variables aleatorias

La función de distribución de probabilidad (acumulada) de la v.a.  $X$  ya sea discreta o continua  $F_X(x)$  representa la probabilidad de que  $X$  toem un menor o igual que  $x$  es decir

$$F_X(x) = P(X \leq x)$$

Sea  $X$  una v.a. y  $F_X$  su función de distribución

$$1. P(X > x) = 1 - P(X \leq x) = 1 - F_X(x)$$

Demostración.- Tenemos que el complementario de  $X$  mayor que  $x$  es  $\overline{\{X > x\}} = \{X > x\}^c = \{X \leq x\}$ . Además

$$P(X > x) = 1 - P(\overline{\{X > x\}}) = 1 - P(X \leq x) = 1 - F_X(x)$$

2. Sea  $a$  y  $b$  tales que  $a < b$ ,

$$P(a < X \leq b) = P(X \leq b) - P(X \leq a) = F_X(b) - F_X(a)$$

Demostración.- Por otro lado, que  $X$  se encuentre entre dos valores  $a$  y  $b$  es  $\{a < X \leq b\} = \{X \leq b\} - \{X \leq a\}$  ahora podemos hacer

$$\begin{aligned} P(a < X \leq b) &= P(\{X \leq b\} - \{X \leq a\}) \\ &= P(\{X \leq b\}) - P(\{X \leq a\}) \\ &= F_X(b) - F_X(a) \end{aligned}$$

## propiedades de la función de distribución

Sea  $F_X$  la función de distribución de un v.a.  $X$  entonces:

- $0 \leq F_X(x) \leq 1$
- La función  $F_x$  es no decreciente.
- Si denotamos por  $F_X(x_0^-) = \lim_{x \rightarrow x_0^-} F(x)$ , entonces se cumple que

$$P(X < x_0) = F_X(x_0^-) \text{ y que } P(X = x_0) = F_X(x_0) - F_X(x_0^-)$$

- Se cumple que  $\lim_{x \rightarrow \infty} F_X(x) = 1$  ;  $\lim_{x \rightarrow -\infty} F_X(x) = 0$
- Toda función  $F$  verificando las propiedades anteriores es función de distribución de alguna v.a.  $X$ .
- $P(X > x) = 1 - F_X(x)$
- Dado  $a, b \in \mathbb{R}$  con  $a < b$

$$P(a < X \leq b) = F_X(b) - F_X(a)$$

## Desigualdades estrictas

- $P(X = x) = F_X(x) - F_X(x^-)$
- $P(a < X < b) = F_X(b^-) - F_X(a)$
- $P(a \leq X < b) = F_X(b^-) - F_X(a^-)$
- $P(X < a) = F_X(a^-)$

### Más propiedades de la función de distribución

- Si  $F_x$  es continua en  $x$  se tiene que  $P(X = x) = 0$  y por lo tanto  $P(X \leq a) = P(X < a) + P(X = a) = P(X < a)$ .

Demostración.- Si  $X$  es continua entonces,

$$P(X = x) = F(a) - F(a^-) = F(a) - F(a) = 0$$

por lo tanto

$$P(X \leq a) = P(X < a) + P(X = x) = P(X < a) + 0 = P(X < a)$$

- Sea  $X$  una v.a. discreta con dominio  $D_X$  y que tiene por función de probabilidad  $P_X(x)$  entonces su función de distribución  $F_X(x_0)$  es

$$F_X(x_0) = \sum_{x \leq x_0} P_X(x)$$

donde  $\sum_{x \leq x_0}$  indica que sumamos todos los  $x \in D_X$  tales que  $x \leq x_0$

Demostración.-

$$F_X(x_0) = P(X \leq x_0) = P\left(\bigcup_{x \leq x_0; x \in D_X} \{x\}\right) = \sum_{x \leq x_0} P(X = x) = \sum_{x \leq x_0} P_X(x)$$

### Valor esperado

$$E(X) = \sum_{x \in X(\Omega)} x P_X(x)$$

En ocasiones se le denomina media poblacional o simplemente media y muy frecuentemente se la denota por

$$\mu_X = E(X) \quad \text{o} \quad \mu = E(X)$$

Si  $n \rightarrow \infty$  se tiene que  $\lim_{n \rightarrow \infty} \frac{n_x}{n} = P_X(x)$  por lo tanto  $E(X) = \lim_{n \rightarrow \infty} \sum_{x=1}^n x \frac{n_x}{n}$  Entonces el valor esperado en una v.a. discreta puede entenderse como el valor promedio que tomaría una v.a. en un número grande de repeticiones.

### Esperanza de funciones de variables aleatorias discretas

Sea  $X$  una v.a. discreta con función de probabilidad  $P_X$  y de distribución  $F_X$ . Entonces el valor esperado de una función  $f(x)$  es:

$$E(g(x)) = \sum_x g(x) P_X(x)$$

### Propiedades de los valores esperados

- $E(k) = k$  para cualquier constante  $k$ .

Demostración.- Se tiene que

$$E(k) = \sum_{x=1}^n k \cdot P(X = k) = k \cdot P(X = k) + \dots + k \cdot P(X = k) = k [P(X = k) + \dots + P(X = k)] = k \cdot 1 = k$$

- Si  $a \leq X \leq b$  entonces  $a \leq E(X) \leq b$

Demostración.- Sea  $E(a) \leq E(X) \leq E(b)$  entonces por la anterior propiedad se tiene que

$$a \leq E(X) \leq b$$

- Si  $X$  es una v.a. discreta que toma valores enteros no negativos entonces  $E(X) = \sum_{x=0}^{\infty} (1 - F_X(x))$

Demostración.- Sea,

$$\begin{aligned}
 E(X) &= \sum_{k=0}^{\infty} k \cdot P(X = k) \\
 &= P(X = 1) \\
 &+ P(X = 2) + P(X = 2) \\
 &+ P(X = 3) + P(X = 3) + P(X = 3) \\
 &+ P(X = 4) + P(X = 4) + P(X = 4) + P(X = 4) \\
 &+ \dots
 \end{aligned}$$

Luego sumando por columnas se tiene,

$$\begin{aligned}
 \sum_{k=1}^{\infty} P(X = k) &= P(X > 0) \\
 \sum_{k=2}^{\infty} P(X = k) &= P(X > 1) \\
 \sum_{k=3}^{\infty} P(X = k) &= P(X > 2) \\
 \sum_{x=0}^{\infty} kP(X = k) &= \sum_{k=0}^{\infty} P(X > k) \\
 E(X) &= \sum_{k=0}^{\infty} 1 - F_X(x)
 \end{aligned}$$

### Propiedades de las series geométricas

- Una progresión geométrica de razón  $r$  es una sucesión de la forma

$$r^0, r^1, r^2, \dots$$

- La serie geométrica es la suma de todos los valores de la progresión geométrica

$$\sum_{k=0}^{\infty} r^k$$

- Las sumas parciales desde el término  $n_0$  al  $n$  de una progresión geométrica valen

$$\sum_{k=n_0}^n r^k = \frac{r^{n_0} - r^{n+1}}{1 - r}$$

- Si  $|r| < 1$  la serie geométrica es convergente y

$$\sum_{k=0}^{\infty} r^k = \frac{1}{1 - r}$$

- En el caso en que se comience en  $n_o$  se tiene que

$$\sum_{k=0}^{\infty} r^k = \frac{r^{n_o}}{1-r}$$

- Si  $|r| < 1$  también son convergentes las derivadas, respecto de  $f$ , de la serie geométrica y convergen a la derivada correspondiente. Así teneos que

$$\begin{aligned} \left( \sum_{k=0}^{\infty} r^k \right)' &= \sum_{k=1}^{\infty} k r^{k-1} \quad y \quad \left( \frac{1}{1-r} \right)' = \frac{1}{(1-r)^2} \\ \left( \sum_{k=0}^{\infty} r^k \right)'' &= \sum_{k=2}^{\infty} k r^{k-2} \quad y \quad \left( \frac{1}{1-r} \right)'' = \frac{2}{(1-r)^3} \end{aligned}$$

Por lo tanto,

$$\begin{aligned} E(X) &= \sum_{x=0}^{\infty} x P(X=x) \\ &= \sum_{x=0}^{\infty} x \left( \frac{1}{2} \right)^{x+1} \\ &= \left( \frac{1}{2} \right)^2 \sum_{x=0}^{\infty} x \left( \frac{1}{2} \right)^{x-1} \\ &= \left( \frac{1}{2} \right)^2 \frac{1}{(1-\frac{1}{2})^2} \\ &= 1 \end{aligned}$$

Luego calculamos su función de distribución

$$\begin{aligned} F_X(x) &= P(X \leq x) \\ &= \sum_{k=0}^x P(X=k) \\ &= \sum_{k=0}^x \left( \frac{1}{2} \right)^{k+1} \\ &= \frac{\frac{1}{2} - \frac{1}{2}^{x+1} \frac{1}{2}}{1 - \frac{1}{2}} \\ &= 1 - \left( \frac{1}{2} \right)^{x+1} \end{aligned}$$

## Momentos de orden m

Llamaremos momento de orden m respecto al punto  $C$  a

$$E[(X - C)^m] = \sum_{x \in X(\Omega)} (X - C)^m \cdot P(x)$$

- Cuando  $C = 0$  los momentos reciben el nombre de momentos respecto al origen.
- Cuando  $C = E(x)$  reciben el nombre de momentos centrales o respecto de la media. Luego la esperanza es el momento de orden 1 respecto al origen. Estos momentos son la versión poblacional.

## Varianza y desviación típica

### La varianza

Sea  $X$  una v.a. Llamaremos varianza de  $X$  a

$$Var(X) = E[(X - E(X))^2]$$

Por lo tanto la varianza es el momento central de orden 2.

de forma frecuente se utiliza la notación

$$\sigma_X^2 = Var(X)$$

A la raíz cuadrada positiva de la varianza

$$\sigma_X = \sqrt{Var(X)}$$

se la denomina desviación típica o estándar de  $X$ .

### Propiedades

- Si  $X$  es una v.a. discreta con función de probabilidad  $P_X$  su varianza es

$$\sigma_X^2 = Var(x) = E[(X - E(X))^2] = \sum_x [x - E(X)]^2 P_X(x)$$

- Sea  $X$  una v.a.

$$Var(X) = E(X^2) - [E(X)]^2 = \sum_x x^2 P_X(x) - [E(X)]^2$$

Demostración.-

$$\begin{aligned} Var(X) &= \sum_x [x - E(X)]^2 P_X(x) \\ &= \sum_x [x^2 - 2xE(X) + E(X)^2] P_X(x) \\ &= \sum_x x^2 P_X(x) - E(X) \sum_x 2x P_X(x) + E(X)^2 \sum_x P_X(x) \\ &= E(X^2) - 2E(X)E(X) + E(X)^2 \\ &= E(X^2) - E(X)^2 \end{aligned}$$

## Propiedades de la varianza

- $Var(X) \geq 0$

Demostración.- La definición nos dice que la diferencia de la v.a.  $X$  y la esperanza del mismo está elevada al cuadrado y por tanto  $Var(X) \geq 0$ .

- $Var(cte) = E(cte^2) - E(cte)^2 = cte^2 - cte^2 = 0$

Demostración.- Dado que la varianza de una constante es la misma constante, entonces  $cte^2 - cte^2$  y por tanto queda demostrada la proposición.

- El mínimo de  $E[(X - C)^2]$  se alcanza cuando  $C = E(X)$  y es  $Var(X)$ . Esta propiedad es una de las que hace útil a la varianza como medida de dispersión.

Demostración.- Sea

$$\begin{aligned} E[(X - C)^2] &= \sum_x (x - C)^2 P_X(x) \\ &= \sum_x (x^2 - 2xC + C^2) P_X(x) \\ &= \sum_x x^2 P_X(x) - 2 \sum_x xC P_X(x) + \sum_x C^2 P_X(x) \\ &= \sum_x x^2 P_X(x) - 2CE(X) + C^2 \end{aligned}$$

Luego derivando e igualando a cero nos queda  $2E(x) - 2C = 0$  y por lo tanto  $C = E(X)$

por último para minimizar necesitamos saber que la no convexidad va hacia arriba realizando su segunda derivada, de donde concluimos que efectivamente se está minimizando.

## Transformaciones lineales de variables aleatorias

Un cambio de variable lineal o transformación lineal de una v.a.  $X$  es otra v.a.  $Y = a + bX$  donde  $a, b \in \mathbb{R}$

### Esperanza de una transformación lineal

Sea  $X$  una v.a. con  $E(X) = \mu_X$  y  $Var(X) = \sigma_X^2$  y  $a, b \in \mathbb{R}$ , entonces si  $Y = a + bX$

- $E(Y) = E(a + bX) = a + b \cdot E(X) = a + b\mu_X$

Demostración.-

$$\begin{aligned} E(Y) &= E(a + bX) \\ &= \sum_x (a + b \cdot x) P_X(x) \\ &= a \sum_x P_X(x) + b \sum_x x \cdot P_X(x) \\ &= a + b \cdot E(X) \\ &= a + b\mu_X \end{aligned}$$

- $Var(Y) = Var(a + bX) = b^2 Var(X) = b^2 \sigma_X^2$

Demostración.-

$$\begin{aligned}Var(Y) = Var(a + bX) &= E[(a + bX)] - [E(a + bX)]^2 \\&= E(a^2 + 2abX + b^2X^2) - [a + bE(X)]^2 \\&= a^2 + 2abE(X) + b^2E(X^2) - a^2 - 2abE(X) - b^2[E(X)]^2 \\&= b^2E(X^2) - b^2[E(X)]^2 \\&= b^2Var(X) \\&= b^2 \cdot \sigma_X^2\end{aligned}$$

- $\sigma_Y = \sqrt{Var(Y)}\sqrt{2^2Var(X)} = |b|\sigma_X$

Demostración.- ya que  $\sqrt{b^2} = |b|$  y en consecuencia del anterior ejercicio se tiene demostrada la proposición mencionada.